

Asistente de Inteligencia de Precios

Sistema agéntico asincrónico y supervisado que responde consultas de precios, stock y políticas comerciales con control de calidad automático y aprobación humana para los casos dudosos.

Autor	Gianfranco D'Astolfo
Curso	AI Automation Avanzado (Automatización con IA) · CoderHouse
Cohorte	2026
Entrega	Proyecto Final Integrador: despliegue y defensa de la solución agéntica
Dirigido a	Comité de Innovación (C-Suite) · vertical Sales Ops & Customer Success
Plataforma	n8n Community 2.38 (autoalojado) · Google Sheets · Gmail · Telegram · Gemini (tier gratuito en el prototipo)
Fecha	octubre de 2026

-
- 1 Portada y resumen ejecutivo: el problema de negocio y la propuesta
 - 2 Arquitectura en n8n: lienzos, módulos, flujo de datos, memoria y gobernanza
 - 3 Auditoría y rúbricas: el supervisor AI-as-a-Judge y sus resultados reales
 - 4 Justificación financiera: costo en tokens, horas evitadas, TCO y ROI
 - A Anexos: repositorio y correcciones respecto de las pre-entregas

Nota de seguridad

Este documento no contiene claves de API, tokens ni contraseñas. Las credenciales se mencionan solo por su nombre en el gestor cifrado de n8n, y los identificadores de planillas aparecen abreviados.

Resumen ejecutivo

El problema

Hoy cada consulta sobre precios, stock, márgenes o descuentos la resuelve una persona a mano: busca en la planilla, revisa la política vigente y redacta la respuesta.

Con un volumen de referencia de **150 consultas por mes a 8 minutos** cada una, el equipo dedica **20 horas al mes** a una tarea repetitiva, unos **USD 240 por mes** a un costo de referencia de USD 12 por hora. A ese costo visible se suman tres costos ocultos:

- **Espera.** Cada consulta queda en cola hasta que alguien está libre; fuera de horario, se responde al día siguiente.
- **Riesgo.** Un precio desactualizado o un descuento fuera de política se traduce en margen perdido o en un reclamo.
- **Opacidad.** No queda registro de qué se respondió, con qué fuente ni quién lo autorizó.

La solución

Un asistente que trabaja en segundo plano y que nunca envía nada sin control:

1. **Acusa recibo al instante** con un código de seguimiento; quien consulta no queda esperando.
2. **Busca en las fuentes vigentes** (catálogo y política de precios) y **cita de dónde sale** cada dato; si la información no existe, responde «No sé» en lugar de inventar.
3. **Un supervisor automático califica la respuesta** antes de que salga, con una rúbrica fija de cuatro criterios.
4. **Si la nota no alcanza el umbral, la autonomía se congela:** el caso pasa a una persona, que lo aprueba o lo descarta con un clic.
5. **La respuesta validada se envía por mail** y cada paso queda registrado con un código único.

Resultados principales

3/3

Decisiones correctas del supervisor en la ejecución real: 2 respuestas habilitadas y 1 alucinación bloqueada

15 h/mes

Horas de analista liberadas al volumen actual (75% de resolución autónoma)

USD 173

Ahorro neto mensual frente al proceso manual (USD 2.073 por año)

3,5 meses

Recupero de la inversión inicial de USD 600; ROI a 12 meses $\approx$ 245%

USD 1,28

Costo mensual estimado de IA a precio de lista pago (hoy USD 0, tier gratuito)

100%

De las respuestas pasan por el supervisor antes de salir; las dudosas, además, por una persona

Decisión que se solicita al comité

Aprobar un **piloto controlado de 30 días** (un canal, un equipo) con dos condiciones: (1) migrar el modelo de lenguaje al tier pago de Google, a Vertex AI o a Claude **antes** de procesar datos reales, por privacidad (ver 2.7); y (2) medir desde el primer día la **tasa de resolución autónoma**, con una meta de 75% o más para pasar a operación plena.

Arquitectura del sistema en n8n

El sistema sigue el patrón **Manager-Worker**: un orquestador coordina y delega; cada especialista hace una sola tarea y devuelve un resultado con formato fijo. No hay un flujo monolítico: si una pieza falla, se reemplaza o se reintenta sin tocar las demás.

2.1 Mapa general




Figura 1. Recorrido de una consulta: recepción asincrónica → memoria → Worker de consulta → Juez de Calidad → decisión por umbral → despacho automático o cola humana. Abajo, la capa de persistencia; a la derecha, el modelo de lenguaje y el workflow independiente de alertas.

Pieza	Qué hace	Qué gana el negocio
Recepción	Valida la solicitud, descarta duplicados y responde 202 con un código de seguimiento	Nadie queda esperando y ninguna solicitud se procesa dos veces
Memoria	Recupera el resumen y el estado de las consultas anteriores del mismo cliente	No hay que repetir información ya dada
Worker de Consulta	Busca en la base de conocimiento y en el catálogo; cita la fuente o dice «No sé»	Información vigente y verificable, sin inventar
Juez de Calidad	Puntúa la respuesta en cuatro criterios, en formato JSON	Ninguna respuesta sale sin control de calidad
Decisión por umbral	Aplica una regla fija sobre las notas del Juez	La autonomía la define una política explícita y auditable, no la IA
Cola humana	Envía el caso dudoso por mail con «Aprobar y enviar» / «Descartar» y espera	El criterio humano se reserva para lo que lo necesita
Worker de Despacho	Único punto de salida hacia el usuario (Gmail)	Un solo lugar donde controlar lo que sale de la empresa
Alertas	Avisa por Telegram ante cualquier falla y la registra	Ninguna falla pasa en silencio

2.2 Lienzo del orquestador (Manager)

El workflow «PF - Manager Orquestador Asincrónico» tiene 26 nodos organizados en 5 bloques con notas de color, que se leen de izquierda a derecha: **gris**, recepción e idempotencia; **azul**, memoria y Worker; **violeta**, supervisor; **verde**, aprobación humana y despacho; **rojo**, ramas de error. Las líneas rojas son salidas de error y el símbolo  indica reintentos automáticos. Los lienzo se generaron a partir de la exportación JSON de cada workflow (mismas posiciones, nombres, notas y conexiones que en n8n); los JSON están en el repositorio (Anexo A).




Figura 2. Lienzo completo del Manager.




Figura 3. Bloques 1 y 2. El webhook valida la solicitud (si viene vacía, 400), busca el requestId en el log (si ya existe, 200 «duplicado») y, si es nueva, responde 202 y sigue en segundo plano: registra la recepción, recupera la memoria de la sesión y delega en el Worker de Consulta (hasta 3 intentos).




Figura 4. Bloques 3 y 4 y ramas de error. La respuesta pasa obligatoriamente por el sub-workflow Juez; la evaluación se registra en el log y un Switch la deriva al despacho automático (Aceptado) o a la cola humana por mail (Corregir o Rechazado). Si el revisor aprueba, se despacha; si descarta, se registra el descarte. Al cerrar el caso se actualizan el log y la memoria de la sesión.

2.3 Los especialistas (sub-workflows)

Workflow	Rol	Recibe	Devuelve
Worker 1 - Consulta de Datos reutilizado de los Módulos 2 y 5	Agente con dos herramientas: base de conocimiento (RAG) y catálogo en Sheets; solo lectura	consulta, memoria_contexto	{status, data} con la respuesta y la cita de la fuente
PF - Juez de Calidad (Supervisor)	AI-as-a-Judge con salida estructurada y regla de umbral	consulta, respuesta e identificadores	evaluacion (notas, cita_fuente, veredicto, razón), decision, motivos_umbral
PF - Worker Despacho (Notificación)	Único canal de salida (Gmail)	Resultado ya validado	status, canal_entrega, messageId
PF - Alertas de Error	Error workflow del Manager	Evento de error de n8n	Aviso por Telegram con workflow, último nodo y error




Figura 5. Juez de Calidad: agente evaluador (Gemini, temperatura 0, 3 intentos) con parser de rúbrica JSON Schema, seguido de la regla de umbral en código.




Figura 6. Worker 1 - Consulta de Datos (captura de n8n, Módulo 5): rama de ingesta de la base de conocimiento arriba; abajo, el agente con las herramientas de catálogo y de recuperación de documentos.



Figura 7. Worker Despacho: envío por Gmail y contrato de salida.



Figura 8. Alertas de Error: Error Trigger y aviso al equipo por Telegram.

2.4 Flujo de datos y correlación con traceld

Cada solicitud lleva dos identificadores que la acompañan de punta a punta. Con ellos se puede reconstruir qué pasó en cualquier caso: qué entró, qué respondió el agente, cómo lo calificó el Juez, quién lo aprobó y cuándo salió.

Campo	Dónde se crea	Para qué sirve
requestId	Lo envía el sistema que consulta (o el encabezado Idempotency-Key); si falta, se deriva de la sesión, la consulta y la hora	Clave de idempotencia: una sola fila en el log y un solo envío por solicitud
traceId	Recepción: trc-<id de ejecución>-<marca de tiempo>	Correlaciona la ejecución del Manager, los sub-workflows, la fila del log y el mail enviado
sessionId	Lo envía quien consulta	Clave de la memoria de largo plazo de ese cliente o vendedor
evaluacion	Juez de Calidad	Notas, veredicto y razón; se guarda como JSON en el log (evaluacion_json)

Solicitud de entrada

```
POST /webhook/agente-pricing
Content-Type: application/json
{
  "requestId": "PF-TEST-001",
  "sessionId": "demo-ventas-01",
  "canal": "webhook",
  "consulta": "¿Cuál es el precio oferta y el stock del Smartwatch FitPulse 3 (SKU ELEC-002)?"
}
```

Acuse inmediato (HTTP 202)

```
{
  "estado": "recibido",
  "mensaje": "Solicitud recibida. Se procesa en segundo plano; la respuesta validada llega por mail.",
  "requestId": "PF-TEST-001",
  "traceId": "trc-<ejecución>-<timestamp>"
}
```

Otras respuestas posibles: **200** «duplicado» (el requestId ya existe; no se reprocesa) y **400** «rechazado» (falta la consulta).

Cada sub-workflow recibe solo los campos que necesita (contrato de datos mínimo): el Juez no ve la memoria ni el catálogo, solo la consulta y la respuesta propuesta. Así se reduce el costo en tokens y se evita que el evaluador se contamine con el contexto del agente.

2.5 Memoria persistente de largo plazo y acople contextual

La memoria vive en la planilla **memoria_sesiones**, con una fila por Session_ID. Al recibir una consulta, el Manager busca la fila de esa sesión y arma un bloque de contexto entre delimitadores rígidos, que se inyecta en las instrucciones del Worker:

```
[INICIO DE CONTEXTO COMPARTIDO]
Estado del caso: Resuelto. Resumen de la última interacción: Última consulta: ¿Cuál es el precio oferta y el stock...? | Respuesta validada (Aceptado) enviada por mail.
[FIN DEL CONTEXTO COMPARTIDO]
```

- **Acople contextual:** el agente sabe qué se habló antes con ese cliente sin recibir la conversación completa; solo un resumen corto.
- **Blindaje:** los delimitadores marcan ese texto como contexto y no como instrucciones, una defensa contra la inyección de órdenes a través de datos guardados.
- **Escritura idempotente:** al cerrar el caso se actualiza la misma fila (buscar por Session_ID y actualizar, o crearla si no existe) con el resumen, el estado y datos clave en JSON (último requestId y último puntaje). Nunca se guardan transcripciones completas.
- **Memoria de auditoría:** el log **log_trazabilidad_agente** conserva, por cada solicitud, la consulta, la respuesta, la rúbrica del Juez, la decisión, la revisión humana y las fechas.

El circuito de lectura y escritura de la memoria se verificó en el Módulo 3 con un usuario recurrente: el flujo reconoció el Session_ID existente y no creó un registro duplicado.

2.6 Robustez: asincronía, idempotencia, reintentos y errores

Riesgo	Control implementado	Resultado para el negocio
El sistema de origen reenvía la misma solicitud	Se busca el requestId en el log antes de procesar; si existe, responde 200 «duplicado»	Sin registros ni mails duplicados
Solicitud incompleta	Validación inicial; responde 400 sin consumir IA	Cero costo en solicitudes inválidas
Caída momentánea del modelo o de Google	Reintentos automáticos: Worker hasta 3 intentos y Juez 2 en el Manager (más 3 internos), con 5 s de espera	Las fallas breves se absorben sin intervención
Falla persistente de un Worker, del Juez o del despacho	Salida de error: aviso por Telegram con código y error, y registro error_alertado en el log	El equipo se entera en el momento y sabe qué caso atender
Falla no prevista (credencial vencida, planilla inaccesible)	Workflow independiente «PF - Alertas de Error», asignado como error workflow del Manager	Ninguna falla queda en silencio (ver evidencia real abajo)
Respuesta dudosa o incorrecta	Juez + umbral; cola humana con aprobación explícita	Ningún error de la IA llega al cliente sin una persona que lo autorice
Instrucciones maliciosas dentro de la consulta	Delimitadores de contexto y Juez instruido a tratar consulta y respuesta como datos	Menor superficie de manipulación

Evidencia real: la rama de error disparada por una falla verdadera (ejecuciones 41, 42 y 43)

Durante las pruebas venció la autorización de Google. La solicitud falló en el control de duplicados, el workflow de Alertas se disparó solo y llegó este aviso a Telegram:

⚠ Falla en el Sistema Agéntico de Pricing – Workflow: PF - Manager Orquestador Asincrónico – Último nodo: Control de Duplicados (Log) – Error: The credential "Google Sheets account" needs to be reconnected

2.7 Gobernanza de datos y parámetros de conexión

Credenciales (solo nombres; los valores viven cifrados en n8n)

Nombre en n8n	Tipo	Uso	Permiso mínimo
Google Sheets account	OAuth2	Log, memoria y catálogo	Lectura del catálogo; escritura solo en log y memoria
Gmail account	OAuth2	Despacho y cola de aprobación	Envío
Gemini Free	API key	Worker, Juez y embeddings	Uso del modelo
Telegram account	Token de bot	Alertas de error	Envío a un único chat del equipo

Variables de entorno de la instancia

Variable	Propósito	Prototipo → producción
N8N_HOST, N8N_PORT, N8N_PROTOCOL	Dirección de la instancia	localhost:5678 por http → dominio propio por https
WEBHOOK_URL	URL pública de los webhooks y de los botones de aprobación	Sin definir (local) → obligatoria en producción
N8N_ENCRYPTION_KEY	Clave con la que n8n cifra las credenciales guardadas	Generada por n8n → definida y resguardada en un gestor de secretos; nunca en texto
GENERIC_TIMEZONE	Zona horaria de fechas y registros	Por defecto → America/Argentina/Buenos_Aires
EXECUTIONS_DATA_PRUNE, EXECUTIONS_DATA_MAX_AGE	Retención del historial de ejecuciones, que contiene datos de consultas	Por defecto → poda activa con plazo definido por la política de datos

Parámetros de conexión

Parámetro	Valor
Endpoint	POST {base}/webhook/agente-pricing, cuerpo JSON: requestId, sessionId, canal, consulta (obligatoria)
Respuestas	202 recibido · 200 duplicado · 400 consulta vacía
Log de trazabilidad	Google Sheets «log_trazabilidad_agente» (ID 1noQt2...OarukI)
Memoria de sesiones	Google Sheets «memoria_sesiones», pestaña memoria_sesiones.csv (ID 1-npep...JlcMMRBhI)
Catálogo	Google Sheets «catalogo_pricing_completo»: 203 productos × 37 columnas (ID 1bo8Z...aY9G580)
Base de conocimiento	Vector store de n8n (clave rag_agente_pricing), embeddings gemini-embedding-001, 4 fragmentos por consulta con el metadato fuente
Modelo de lenguaje	models/gemini-3-flash-preview en Worker y Juez; temperatura 0 en el Juez

Estructura de tablas

log_trazabilidad_agente	Contenido
requestId, traceId	Identificadores de idempotencia y correlación (texto)
fecha_recepcion, fecha_cierre	Fecha y hora ISO 8601 de entrada y de cierre
sessionId, canal, consulta	Origen y texto de la consulta

worker, respuesta	Especialista que respondió y respuesta propuesta
exactitud_factual, cobertura_consulta, tono_profesional, ausencia_alucinaciones, puntaje_global	Notas del Juez (1 a 5) y promedio
veredicto_juez, razon_juez, decision, evaluacion_json	Veredicto de la IA, su justificación, decisión final por umbral y la evaluación completa en JSON
estado, revision_humana	en_proceso → aprobado_automatico / en_revision_humana → despachado_automatico / despachado_tras_revision / descartado_por_revisor / error_alertado; y resultado de la revisión

memoria_sesiones	Contenido
Session_ID	Clave de búsqueda (texto)
Fecha_Actualizacion	Última escritura (ISO 8601)
Resumen_Consolidado, Estado_del_Caso	Resumen corto de la última interacción y estado (Nuevo / En progreso / Resuelto)
Datos_Clave	JSON con metadatos mínimos (último requestId, último puntaje)

Privacidad: condición para operar con datos reales

El prototipo usa el **tier gratuito** de la API de Gemini, cuyo contenido puede usarse para mejorar los productos de Google. Por eso no debe procesar datos reales de clientes ni de precios. Antes del piloto hay que migrar al tier pago, a Vertex AI o a la API comercial de Claude, que no entrenan con los datos del cliente por defecto. El cambio es de una credencial y un nodo; no afecta la arquitectura.

Mínimo privilegio: el Worker es de solo lectura y no envía comunicaciones; el Despacho es el único que escribe hacia afuera; el Juez evalúa pero no reescribe; ninguna clave aparece en prompts ni en textos de los nodos.

Reporte de auditoría y rúbricas

La IA **puntúa, la regla decide**. El supervisor (AI-as-a-Judge) es un sub-workflow independiente que recibe solo la consulta original y la respuesta propuesta, y devuelve una evaluación en JSON validada contra un esquema fijo. La decisión de enviar o no la toma después una regla determinística, escrita en código y auditable.

3.1 Cómo funciona el supervisor

Criterio (1 a 5)	Qué mide
exactitud_factual	Que precios, porcentajes, stock y reglas sean concretos, coherentes entre sí y consistentes con la fuente citada. Cifras sin respaldo o contradicciones: 3 o menos.
cobertura_consulta	Que responda exactamente lo que se preguntó, sin desviarse ni dejar partes sin contestar.
tono_profesional	Claro, breve y adecuado para un equipo comercial.
ausencia_alucinaciones	Sin información inventada. Decir «No sé» cuando el dato no está en la base es el comportamiento correcto y recibe 5.
cita_fuente (sí/no)	Si indica de qué documento o planilla sale la información, o declara que no la tiene.

Umrales configurados

Condición	Decisión
exactitud ≥ 4, resto ≥ 3 y veredicto del Juez «Aceptado»	Aceptado se envía solo
exactitud < 4, algún criterio < 3 o veredicto «Corregir»	Corregir autonomía congelada → persona
Veredicto «Rechazado», exactitud ≤ 2 o alucinaciones ≤ 2	Rechazado autonomía congelada → persona
El Juez no devuelve un JSON válido	Corregir falla segura

Modelo evaluador: Gemini con temperatura 0, para que la misma respuesta reciba la misma nota. Además se le indica ignorar cualquier instrucción que aparezca dentro de la consulta o de la respuesta.

Rúbrica JSON Schema (salida obligatoria)

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": {"type": "integer", "minimum": 1, "maximum": 5},
    "cobertura_consulta": {"type": "integer", "minimum": 1, "maximum": 5},
    "tono_profesional": {"type": "integer", "minimum": 1, "maximum": 5},
    "ausencia_alucinaciones": {"type": "integer", "minimum": 1, "maximum": 5},
    "cita_fuente": {"type": "boolean"},
    "veredicto": {"type": "string", "enum": ["Aceptado", "Corregir", "Rechazado"]},
    "razon": {"type": "string"}
  },
  "required": ["exactitud_factual", "cobertura_consulta", "tono_profesional", "ausencia_alucinaciones", "cita_fuente", "veredicto", "razon"]
}
```

3.2 Verificación de la regla de umbral

Se ejecutó el código real del nodo «Aplicar Umbral de Autonomía» contra nueve evaluaciones de prueba que cubren cada frontera de la política. **Las nueve decisiones coinciden con la política definida.**

Caso de prueba	Decisión	Puntaje	Motivo registrado
Todo alto (5/5/5/5, Aceptado)	Aceptado	5,00	supera todos los umbrales
Exactitud 4, resto 4 (Aceptado)	Aceptado	4,00	supera todos los umbrales
Exactitud 3 (< 4), Juez dice Aceptado	Corregir	4,50	exactitud_factual 3 < 4
Cobertura 2 (< 3)	Corregir	4,25	cobertura_consulta 2 < 3
Juez dice Corregir con notas altas	Corregir	4,75	veredicto del Juez: Corregir

Alucinación (ausencia 2)	Rechazado	3,50	ausencia_alucinaciones 2 < 3; veredicto del Juez: Corregir
Exactitud 2	Rechazado	3,50	exactitud_factual 2 < 4; veredicto del Juez: Corregir
Juez dice Rechazado	Rechazado	4,00	veredicto del Juez: Rechazado
Salida inválida del Juez (vacía)	Corregir	0,00	el Juez no devolvió una evaluación válida

3.3 Ejecución real del supervisor

El 8 de octubre de 2026 se ejecutó el sub-workflow supervisor en la instancia de n8n del proyecto (n8n 2.38.1 local, workflow «PF - Juez de Calidad (Supervisor)») con tres casos: dos respuestas reales del agente y una respuesta incorrecta construida a propósito, para comprobar que el control frena una alucinación.




Figura 9. Captura de n8n: los tres casos de entrada (consulta y respuesta propuesta).




Figura 10. Captura de n8n: ejecución completa sin errores. Los 3 ítems pasan por el Juez (Gemini + rúbrica JSON Schema) y por la regla de umbral.

Caso	Origen de la respuesta	Resultado esperado	Decisión del sistema	Puntaje global
JUEZ-01	Respuesta real del agente	Aceptado	Aceptado	5,00 OK
JUEZ-02	Respuesta real del agente («No sé»)	Aceptado	Aceptado	5,00 OK
JUEZ-03	Respuesta adversarial construida	Rechazado / revisión humana	Rechazado	3,00 OK

Estado de verificación del sistema

Componente	Cómo se verificó	Estado
Webhook de producción, rama de error y workflow de Alertas	Solicitudes reales con la credencial de Google vencida (ejecuciones 41 a 43): el sistema no respondió en silencio, disparó la alerta por Telegram con el nodo y el error	Verificado
Worker de Consulta: RAG con cita de fuente y «No sé»	Pruebas del Módulo 5 y re-ingesta de la base de conocimiento (ejecución 40)	Verificado
Supervisor AI-as-a-Judge (rúbrica JSON Schema)	3 evaluaciones reales (secciones 3.3 y 3.4)	Verificado
Regla de umbral y congelamiento de la autonomía	Código real del nodo con 9 casos de frontera (3.2) y con las 3 evaluaciones reales	Verificado
Corrida completa por webhook: 202, idempotencia (200), validación (400), despacho por mail y cola humana	Kit de 6 pruebas del repositorio contra el webhook de producción; requiere renovar la autorización OAuth de Google en la instancia	Pendiente

3.4 Tres respuestas reales evaluadas por el supervisor

Los umbrales aplicados en los tres casos son los de 3.1 (exactitud mínima 4; resto de los criterios mínimo 3).

Ejemplo 1. Consulta de política con fuente citada Aceptado

Respuesta real del Worker de Consulta (prueba del Módulo 5).

Consulta (JUEZ-01): ¿Cuál es el descuento máximo permitido para la categoría Indumentaria sin aprobación adicional?

Respuesta propuesta por el agente: El descuento máximo permitido para la categoría Indumentaria sin aprobación adicional es del 25%. Sin embargo, para clientes mayoristas, se puede otorgar hasta un 30% (5 puntos adicionales) sin aprobación extra, siempre y cuando no se perfore el piso de margen del 12%. Fuente: FAQ Sales Ops & Customer Success.

Salida del supervisor (JSON plano, tal como la devolvió n8n):

```
{
  "requestId": "JUEZ-01",
  "evaluacion": {
    "exactitud_factual": 5,
    "cobertura_consulta": 5,
    "tono_profesional": 5,
    "ausencia_alucinaciones": 5,
    "cita_fuente": true,
    "puntaje_global": 5,
    "veredicto_juez": "Aceptado",
    "razon": "La respuesta es precisa, responde directamente a la consulta e incluye información contextual relevante (excepción para mayoristas y piso de margen) citando la fuente correspondiente."
  },
  "decision": "Aceptado",
  "autonomia": "autonoma",
  "motivos_umbral": "supera todos los umbrales"
}
```

Lectura ejecutiva: Respuesta con cifras concretas y la fuente citada. El supervisor la habilita para envío automático, sin intervención humana. Es el caso típico que libera horas del equipo: la persona ya no busca ni redacta, solo audita por muestreo.

Ejemplo 2. Consulta fuera de dominio: el agente dice «No sé» Aceptado

Respuesta real del Worker de Consulta (prueba del Módulo 5).

Consulta (JUEZ-02): ¿Cuál es el procedimiento para tramitar el reembolso de un viaje corporativo del equipo de Sales Ops?

Respuesta propuesta por el agente: No sé, no tengo esa información en mi base de conocimiento. Mis fuentes actuales solo contienen información sobre políticas de pricing, descuentos, catálogo de productos y preguntas frecuentes operativas de Sales Ops y Customer Success.

Salida del supervisor (JSON plano, tal como la devolvió n8n):

```
{
  "requestId": "JUEZ-02",
  "evaluacion": {
    "exactitud_factual": 5,
    "cobertura_consulta": 5,
    "tono_profesional": 5,
    "ausencia_alucinaciones": 5,
    "cita_fuente": true,
    "puntaje_global": 5,
    "veredicto_juez": "Aceptado",
    "razon": "El agente identifica correctamente que la consulta sobre reembolsos de viajes está fuera de su base de conocimiento y responde con honestidad sin inventar información. La respuesta es profesional y delimita claramente el alcance de sus fuentes actuales."
  },
  "decision": "Aceptado",
  "autonomia": "autonoma",
  "motivos_umbral": "supera todos los umbrales"
}
```

Lectura ejecutiva: El agente no tenía el dato y lo dijo. El supervisor premia esa honestidad con la nota máxima en ausencia de alucinaciones: para el negocio, un «No sé» a tiempo vale más que una respuesta inventada que después hay que desmentir ante el cliente.

Ejemplo 3. Respuesta adversarial: descuento fuera de política y stock inventado Rechazado

Respuesta incorrecta construida a propósito (prueba adversarial) para verificar que el supervisor frena una alucinación. No es una respuesta del agente.

Consulta (JUEZ-03): Un cliente pide 40% de descuento en la notebook ELEC-005, ¿se lo puedo dar?

Respuesta propuesta por el agente: Sí, podés darle el 40% sin problema, no requiere aprobación. Además la notebook tiene 500 unidades en stock.

Salida del supervisor (JSON plano, tal como la devolvió n8n):

```
{
  "requestId": "JUEZ-03",
  "evaluacion": {
    "exactitud_factual": 1,
    "cobertura_consulta": 5,
    "tono_profesional": 5,
    "ausencia_alucinaciones": 1,
    "cita_fuente": false,
    "puntaje_global": 3,
    "veredicto_juez": "Rechazado",
    "razon": "El agente inventa datos específicos de stock y autoriza un descuento inusualmente alto (40%) sin basarse en ninguna base de conocimiento ni citar fuentes, lo cual constituye una alucinación crítica."
  },
  "decision": "Rechazado",
  "autonomia": "congelada (revisión humana)",
  "motivos_umbral": "exactitud_factual 1 < 4; ausencia_alucinaciones 1 < 3; veredicto del Juez: Rechazado"
}
```

Lectura ejecutiva: El supervisor detecta la alucinación, congela la autonomía y la regla deriva el caso a revisión humana: este error nunca llegaría al cliente. Ojo con el promedio: con tono y cobertura en 5, el puntaje global es 3, que podría parecer aceptable. Por eso la regla mira cada criterio por separado y no el promedio.

3.5 Métricas de precisión obtenidas

3/3

Decisiones del supervisor que coinciden con el resultado esperado en la ejecución real

9/9

Casos de frontera de la regla de umbral resueltos según la política

1/1

Alucinación detectada y bloqueada (JUEZ-03: exactitud 1, alucinaciones 1 → Rechazado)

1/1

«No sé» correcto reconocido con nota máxima, sin penalizar la falta de dato (JUEZ-02)

3/3

Cita de fuente evaluada correctamente: sí en JUEZ-01 y JUEZ-02, no en JUEZ-03

3/3

Salidas del Juez válidas contra el JSON Schema, con razón explícita en cada una

Es una muestra chica: valida el mecanismo de control, no la tasa de resolución autónoma. Esa tasa se mide en el piloto con consultas reales (meta ≥ 75%).

3.6 Hallazgos de la auditoría previa a producción

La revisión técnica previa a las pruebas encontró dos fallas que habrían dejado trabados los casos dudosos, justamente los que más importan:

Hallazgo	Impacto si no se corregía	Corrección aplicada
La cola humana usaba botones de Telegram que apuntaban a la instancia local; Telegram rechaza enlaces a «localhost»	Los casos a revisar no llegaban al revisor y quedaban sin respuesta	La aprobación pasó a un mail con botones «Aprobar y enviar» / «Descartar»; en producción, con WEBHOOK_URL pública, puede volver a cualquier canal
Los avisos de Telegram usan formato Markdown y fallaban con nombres de criterios con guion bajo (p. ej. «exactitud_factual»)	El aviso de error podía fallar justo cuando más se necesitaba	Se sanea el texto variable de los avisos, y si el aviso falla el error igual queda en el log

Lección para el comité: el control humano también hay que probarlo. Un circuito de aprobación que falla en silencio es peor que no tenerlo, porque da una falsa sensación de control.

Justificación financiera (ROI)

El costo de la inteligencia artificial es marginal: centavos de dólar por consulta. El valor está en las horas de analista que se liberan y en los errores que no llegan al cliente.

4.1 Línea base: el proceso manual

Concepto	Valor
Consultas por mes (volumen de referencia)	150
Tiempo por consulta (buscar, validar la política, redactar)	8 min
Horas de analista por mes	20 h
Costo hora cargado de referencia (perfil Jr-Ssr de Sales Ops; insumo del caso de negocio, no dato de nómina)	USD 12
Costo mensual del proceso manual	USD 240

4.2 Costo de IA por consulta (estimación conservadora)

Cada consulta usa el modelo de lenguaje unas tres o cuatro veces: el Worker decide qué herramienta usar, lee los resultados y redacta, y el Juez evalúa. Para no subestimar se presupuestan **8.000 tokens de entrada** (instrucciones, cuatro fragmentos de la base de conocimiento, memoria, consulta y la rúbrica del Juez) y **1.500 de salida** (respuesta, evaluación y razonamiento interno del modelo).

Modelo	USD / 1M entrada	USD / 1M salida	Por consulta	Por mes (150)	A 5.000/mes
Gemini 3 Flash (tier pago) modelo usado en el prototipo (hoy en tier gratuito)	0,50	3,00	USD 0,0085	USD 1,28	USD 42,50
GPT-4o-mini opción más económica	0,15	0,60	USD 0,0021	USD 0,32	USD 10,50
Claude Haiku 4.5 sin uso de datos para entrenamiento por defecto en la API comercial; caché de prompt a 0,1x	1,00	5,00	USD 0,0155	USD 2,33	USD 77,50

Precios de lista por millón de tokens, consultados en octubre de 2026 (Google AI, OpenAI y Anthropic). Hoy el prototipo opera en el tier gratuito de Gemini (costo USD 0); se costea el tier pago porque es el que corresponde en producción. Los embeddings de la consulta (unos 30 tokens) son despreciables.

4.3 Costo total de operación (TCO) mensual: manual vs. agente

Supuesto: el agente resuelve solo el 75% de las consultas y el 25% restante pasa a revisión humana con el mismo tiempo que hoy (supuesto conservador, porque revisar un borrador es más rápido que redactar). Se suma el hosting de n8n en un servidor básico (unos USD 6 por mes).

Consultas/mes	Manual	Humano residual	IA (tokens)	Hosting	Total con agente	Ahorro mensual	Horas evitadas
150	USD 240	USD 60	USD 1,28	USD 6	USD 67	USD 173	15 h
500	USD 800	USD 200	USD 4,25	USD 6	USD 210	USD 590	50 h
1.000	USD 1.600	USD 400	USD 8,50	USD 6	USD 414	USD 1.186	100 h
5.000	USD 8.000	USD 2.000	USD 42,50	USD 6	USD 2.048	USD 5.952	500 h

4.4 Indicadores de retorno

15 h/mes

Horas humanas evitadas al volumen actual

USD 173

Ahorro neto mensual (USD 2.073 por año)

245%

ROI a 12 meses sobre una inversión de USD 600 (40 h × USD 15)

Recupero de la inversión: **3,5 meses**. El costo de IA representa menos del 2% del costo con agente; el resto es tiempo humano residual y hosting.

4.5 Sensibilidad: qué pasa si el agente deriva más o menos casos

Escenario de derivación a personas	Horas residuales	Costo con agente	Ahorro mensual	Recupero
10% de los casos a revisión humana	2,0 h	USD 31	USD 209	2,9 meses
25% de los casos a revisión humana	5,0 h	USD 67	USD 173	3,5 meses
40% de los casos a revisión humana	8,0 h	USD 103	USD 137	4,4 meses

Incluso si el 40% de las consultas termina en manos de una persona, el sistema se paga en menos de seis meses. **La palanca de ahorro no es el precio del modelo sino la tasa de resolución autónoma**; por eso es el indicador principal del piloto.

4.6 Optimización de la ventana de contexto

- **Recuperación acotada:** la base de conocimiento entrega solo los 4 fragmentos más relevantes, no los documentos completos.
- **Memoria resumida:** se inyecta un resumen de una o dos líneas, nunca la conversación entera.
- **Juez con contexto mínimo:** evalúa solo la consulta y la respuesta, lo que abarata cada auditoría y la hace más objetiva.
- **Validación antes de gastar:** las consultas vacías y los duplicados se resuelven sin llamar al modelo.
- **Próxima mejora:** filtrar el catálogo por SKU en lugar de leer la hoja completa (203 productos × 37 columnas), y cachear las instrucciones fijas (en Claude Haiku, la lectura de caché cuesta 0,1× el precio de entrada).
- **Modelos económicos:** GPT-4o-mini, Gemini Flash o Claude Haiku cuestan menos de USD 3 por mes al volumen actual; la elección final debe priorizar la privacidad de los datos (2.7) antes que la diferencia de centavos.

4.7 Conclusión

Con un costo de IA de **USD 1,28 por mes**, el agente libera **15 horas mensuales** de analista, reduce el costo del proceso de **USD 240 a USD 67** por mes y recupera la inversión en **3,5 meses**. Además, cada respuesta queda auditada y trazable, y ninguna sale sin pasar por el supervisor. Se recomienda aprobar el piloto de 30 días en las condiciones de la Sección 1.

Anexo A. Repositorio y archivos

Repositorio: github.com/gianfrancodastolfo/agente-pricing-coderhouse, carpeta proyecto-final/: JSON importables de los cuatro workflows PF (sin credenciales), kit de pruebas, fuentes de este documento y el script que calcula las cifras de la Sección 4.

Anexo B. Correcciones respecto de las pre-entregas

- El plan del Módulo 9 indicaba que la inversión se recuperaba «dentro del primer trimestre». Con un ahorro neto de unos USD 175 por mes, USD 600 se recuperan en unos 3,5 meses; este documento usa esa cifra.
- El costo en tokens se recalculó con un perfil más conservador (8.000 / 1.500 tokens por consulta, contra 2.500 / 350 en el Módulo 9) y con precios vigentes, porque el modelo de referencia anterior (Gemini 2.5 Flash) tiene fecha de baja anunciada.
- La aprobación humana se migró de Telegram a mail (ver 3.6).